

Lista de Exercícios – 03

Busca de padrões em texto

- Sobre os algoritmos KMP e Rabin-Karp (RK) vistos em sala, responda Verdade (V) ou Falso (F) para as afirmações a seguir. Para tanto, suponha que o padrão $P[1 : 4] = x_1x_2x_3x_4$, com x_i representando símbolos de um alfabeto Σ . Considere ainda que o pré-processamento do algoritmo KMP gerou uma tabela $\pi = [0, a, b, c]$, sendo a, b e c valores numéricos.
 - Se $x_4 \neq x_1$, então $c = 0$.
 - Se $b > a$, então $x_1 = x_3$.
 - Ao se buscar o padrão num texto qualquer pelo algoritmo KMP, sabe-se que o número mínimo de comparações ocorre quando $a = b = c = 0$.
 - $b \leq c$.
 - Suponha que o padrão P ocorre pela primeira vez num texto T na posição t . Então, o número de comparações realizadas durante a busca de P em T pelo algoritmo RK é $t + 4$ no melhor caso e $4t$ no pior caso.
 - É possível afirmar que o maior número de comparações para o algoritmo RK ocorre ao se buscar o padrão “AAAB” num texto “AA...A”.
 - É possível adaptar o algoritmo RK para se buscar padrões de símbolos numa matriz.
 - Suponha, devido a um erro de implementação no método RK, $1/k$ é probabilidade de colisão para buscar um padrão de tamanho m num texto de tamanho $n > m$, com $k > 0$ uma constante. Sob estas condições, é possível afirmar que esta busca levará um tempo $O(n + m)$ se $k \geq m/4$.
- Considere o pré-processamento do algoritmo KMP, tal como visto em sala, para um padrão P de tamanho $m = 10$, para o qual a tabela produzida foi $\pi = [0, 0, 1, 2, 3, 0, 1, 2, 3, 0]$. Quais as posições de P que foram comparadas com $P[10]$ quando se calculou o valor $\pi[10] = 0$? Considere a indexação de P e de π iniciando de 1.
- Mostre um exemplo de texto T de tamanho $n = 20$ e padrão P de tamanho $m = 5$ em que o método de busca de Boyer-Moore faz o menor número de comparações. Assuma que P é sufixo de T e só ocorre uma vez em T . Qual o número de comparações feitas?
- Considerando o algoritmo KMP, mostre um exemplo de padrão P e texto T que caracteriza o pior caso numa busca de P em T , com $|P| = 5$ e $|T| = 10$. Para seu exemplo ser considerado, a tabela π associada ao padrão deve ser mostrada e estar coerente com o exemplo dado. Informe ainda o número de comparações realizadas durante a busca de P em T .
- Para o padrão:

a a b a a b a a

e o texto:

a a b a a a b a a b a a b a a a b a a b a a

apresente as tabelas utilizadas e as comparações realizadas para se procurar este padrão no texto para os seguintes algoritmos:

- busca de padrão com autômatos finitos
 - KMP (Knuth, Morris, Pratt)
- Considerando o algoritmo de busca de padrão em texto com o uso de autômatos finitos e o padrão abaixo:

$x \ y \ x \ y \ x \ x \ y$

apresente:

- (a) a tabela que representa o autômato para este padrão (função δ)
- (b) as comparações realizadas pelo algoritmo para o texto:

$x\ x\ y\ x\ y\ x\ y\ x\ x\ y\ x\ y\ x\ x\ y\ x$

- (c) quais comparações seriam feitas pelo algoritmo ingênuo de busca.

7. Considerando-se o padrão:

$a\ a\ b\ c\ a\ a\ a$

e o texto:

$a\ a\ b\ a\ a\ a\ a\ a\ b\ b\ a\ a\ b\ c\ b\ c\ a\ a\ b\ c\ a\ a\ a$

faça o que se pede abaixo:

- (a) para o algoritmo de busca com uso de autômatos, apresente a tabela de transição de estados e a sequência de estados do autômato durante uma busca pelo padrão no texto
8. Mostre a tabela de transição para o algoritmo de busca de padrão com o uso de autômato e represente a execução deste algoritmo (sequência de transições de estado) para encontrar o padrão *aaabaaa* no texto abaixo:

$a\ a\ a\ b\ a\ a\ b\ a\ b\ a\ b\ a\ a\ a\ a\ b\ a\ b\ a\ a\ b\ a\ a\ b\ b\ b\ a\ a\ b\ a\ a\ a\ b\ a\ a\ a$

Compressão da dados

1. Usando o algoritmo de compressão de Huffman (estático), encontre o número total de bits necessários para comprimir os seguintes textos (sem considerar a codificação do cabeçalho, apenas o texto). Forneça ainda a redundância do código gerado.

- (a) “ABADEEEEACCCCBADDEEE”.
- (b) “AAABFCFFADE”.

2. Apresente uma codificação de Huffman (estático) para cada um dos conjuntos de caracteres abaixo (os valores entre parênteses correspondem às frequências das letras):

- (a) A (40%), B (15%), C (5%), D (13%), E (3%), F (2%), G (7%), H (15%)
- (b) A (5%), B (7%), C (15%), D (13%), E (30%), F (10%), G (12%), H (8%)
- (c) A (10%), B (30%), C (15%), D (5%), E (15%), F (5%), G (20%)
- (d) A (5%), B (30%), C (15%), D (7%), E (15%), F (20%), G (8%)

3. Apresente uma codificação para os caracteres do texto abaixo, considerando as versões Huffman estático e dinâmico:

$a\ a\ a\ a\ b\ b\ b\ c\ d\ a\ a\ a\ d\ e\ d\ a\ a\ b\ b\ b\ a\ c$

4. Indique se a frase seguinte é verdadeira ou falsa e justifique: em uma árvore binária representando uma codificação livre de prefixo (*prefix code*) ótima, é possível haver um ou mais nós internos (nós que não são folhas) com apenas um nó filho.
5. Qual saída do para o texto “AABABBCBCBBB” de acordo com o método Huffman dinâmico?
6. Exiba o código gerado pelo método LZW para o texto “ababcbababaaaaaa”, considerando o dicionário $\{0 : a; 1 : b; 2 : c\}$.
7. Quais seriam as codificações geradas para o texto da questão anterior usando os codificadores LZ77 e LZ78? Para LZ77, considere que os tamanhos da janela deslizante é grande o suficiente para conter todo o texto.
8. Considere que o dicionário inicial usado pelo compressor/descompressor LZW é $\{0 : A; 1 : B; 2 : C\}$. Sabendo que o código recebido pelo descompressor é

$0\ 0\ 1\ 3\ 5\ 0\ 2$

qual o texto original? Mostre ainda a configuração final do dicionário.

9. Considerando um alfabeto contendo apenas as letras a e b , como seria o resultado da compressão do texto abaixo pelos algoritmos LZ77, LZ78 e LZW.

a a a b a a b a b a b a a a a a

10. Considerando um alfabeto contendo apenas as letras a e b , apresente o resultado da descompressão da sequência abaixo e a tabela criada pelo algoritmo LZW:

0 1 2 3 1

Considere que as letras a e b estão nas entradas 0 e 1 da tabela, respectivamente.

Ordenação externa

1. Um arquivo A deve ser ordenado usando algum dos algoritmos para ordenação em memória externa vistos em sala. Para tanto, precisa-se gerar as sequências ordenadas iniciais (*runs*). Usando o método de seleção por substituição para fazê-lo e assumindo que a memória interna disponível comporta 3 registros, quais registros estariam na terceira sequência gerada? Considere que A contém os registros com as seguintes chaves e na seguinte ordem:

80 13 33 5 56 43 62 18 100 6 1 30 21 94 92 86 36 75 81 53

2. Supondo que há 54 sequências iniciais de registros a serem ordenados pelo método de ordenação polifásica, quantos passos serão necessários para obter todos os registros ordenados, sabendo-se que há apenas três arquivos a serem utilizados durante os passos de ordenação?
3. Repita a questão 2, mas agora considerando 4 arquivos.
4. Apresente os passos para ordenação da seguinte sequência de chaves, armazenadas em um arquivo, considerando o método de intercalação balanceada de p -caminhos:

13, 5, 40, 35, 30, 20, 12, 10, 1, 7, 25, 6,
45, 21, 50, 51, 2, 22, 55, 11, 3, 4, 8, 7

Somente podem ser utilizados 4 arquivos. Considere $p = 2$ e que somente 3 registros podem ser ordenados por vez na memória principal.

5. Refaça a questão anterior, considerando a seguinte sequência de chaves:

13, 5, 40, 35, 30, 20, 12, 10, 1, 7, 25, 6, 45, 21, 50

6. Refaça os exercícios das questões 4 e 5 considerando intercalação polifásica com:

- (a) 3 arquivos
- (b) 4 arquivos
- (c) 5 arquivos

Qual dos métodos resultou em um número menor de registros processados, em cada caso?

7. Refaça os exercícios 4 e 5 considerando intercalação em cascata (*cascade merge*) e as quantidades de arquivos indicadas na questão 5.
8. Como devem ser distribuídas 49 sequências ordenadas (*runs*) em 5 arquivos na intercalação polifásica? Um dos arquivos deve estar vazio.
9. Qual a vantagem do uso de *heaps* na fase de intercalação de sequências ordenadas (*runs*) no método de intercalação balanceada de P -caminhos?
10. Sejam n o número de registros e m o tamanho de uma *run* (sequência de registros ordenados). Qual é o número de interações (processamento de todas as *runs*) quando se utiliza intercalação balanceada de P caminhos? Justifique.
11. A figura abaixo representa o número de sequências ordenadas (*runs*) em 5 arquivos, denominados A_1, A_2, A_3, A_4, A_5 (um traço indica que não há sequências no arquivo).

A_1	A_2	A_3	A_4	A_5
15	14	12	8	-

Indique o número de sequências ordenadas em cada arquivo em cada etapa do algoritmo de ordenação polifásica, até que se tenha apenas uma sequência em um dos arquivos.

Respostas

Busca de padrões em texto

- 1a. F
- 1b. V
- 1c. V
- 1d. F
- 1e. V
- 1f. F
- 1g. V
- 1h. V
- 2. 4, 3, 1.
- 3. $T = \text{"aaaaaaaaaaaaabbbbb"}$ e $P = \text{"bbbbbb"}$. Serão 8 comparações.
- 4. $T = \text{"aaaabaaaa"}$ e $P = \text{"aaaaa"}$. Serão 14 comparações neste exemplo e $\pi = [0, 1, 2, 3, 4]$.

Compressão de dados

- 1a. Código comprimido terá 43 bits. Como a entropia do texto é 2.23/símbolo, a codificação ótima geraria 42,37 bits no total. A redundância do código gerado é de 0,63 bit.
- 1b. Código comprimido terá 26 bits e a redundância é de 0,92 bit, pois a entropia é de 2.28 bits/símbolo.
- 5. O código gerado será $c(A)10c(b)B1010100c(C)11101000$, com $c(s)$ representando o código binário do símbolo s .
- 6.
- 8. "aabaabaac".

Ordenação externa

- 1. $\{1, 6, 21, 30, 86, 92, 94\}$.
- 2. 8 passos de intercalação.
- 3. 6 passos de intercalação.